

Klasifikasi Jenis Burung Berdasarkan Suara Kicau Menggunakan Ekstraksi MFCC dan BiLSTM

Roikhatul Janah¹, Eko Budi Susanto², Tri Agus Setiawan³

^{1,2,3} Program Studi Sistem Informasi Fakultas Teknologi Informasi, Institut Widya Pratama
E-mail : ekobudi.s@stmik-wp.ac.id

Abstrak

Klasifikasi otomatis jenis burung berdasarkan suara kicau menjadi solusi penting untuk mendukung upaya konservasi keanekaragaman hayati Indonesia yang memiliki 1.835 spesies burung. Penelitian ini mengusulkan sistem klasifikasi yang mengkombinasikan ekstraksi fitur *Mel-Frequency Cepstral Coefficients (MFCC)* dengan arsitektur *Bidirectional Long Short-Term Memory (BiLSTM)* untuk mengidentifikasi 10 spesies burung Indonesia yang umum dijumpai. Dataset penelitian menggunakan 750 rekaman suara burung dari platform *xeno-canto.org* yang disegmentasi menjadi durasi 4 detik dan diperbanyak menjadi 3.750 sampel melalui teknik augmentasi *pitch shift* dan *time stretch*. Ekstraksi fitur MFCC dengan 40 koefisien digunakan untuk merepresentasikan karakteristik spektral suara burung, sedangkan model BiLSTM dipilih untuk menangkap dependensi temporal bi-directional yang kompleks dalam sinyal vokal burung. Dalam proses pengujian dilakukan pembagian data 80:20 untuk *training* dan *testing*. Analisis confusion matrix mengkonfirmasi kemampuan model dalam membedakan karakteristik unik setiap spesies dengan tingkat kesalahan minimal. Hasil penelitian menunjukkan bahwa sistem mampu mencapai akurasi klasifikasi sebesar 98%. Kombinasi MFCC dan BiLSTM terbukti efektif untuk aplikasi pemantauan biodiversitas dan konservasi burung Indonesia secara otomatis dan berkelanjutan.

Kata kunci : Klasifikasi Burung, MFCC, BiLSTM, Pengolahan Sinyal Audio, Konservasi Biodiversitas

Bird Species Classification Based on Chirping Sounds Using MFCC Feature Extraction and BiLSTM

Abstract

Automatic bird species classification based on chirping sounds has become an important solution to support conservation efforts for Indonesia's biodiversity, which comprises 1.835 bird species. This study proposes a classification system that combines Mel-Frequency Cepstral Coefficients (MFCC) feature extraction with Bidirectional Long Short-Term Memory (BiLSTM) architecture to identify 10 commonly found Indonesian bird species. The research dataset utilized 750 bird sound recordings from the xeno-canto.org platform, segmented into 4-second duration clips and augmented to 3,750 samples through pitch shift and time stretch techniques. MFCC feature extraction with 40 coefficients was employed to represent the spectral characteristics of bird sounds, while the BiLSTM model was selected to capture complex bi-directional temporal dependencies in bird vocal signals. In the testing process, an 80:20 data split was performed for training and testing. Confusion matrix analysis confirms the model's capability to distinguish unique characteristics of each species with minimal error rates. Research results demonstrate that the system achieved a classification accuracy of 98%. The combination of MFCC and BiLSTM proves effective for automated and sustainable biodiversity monitoring and bird conservation applications in Indonesia.

Keywords : Bird Classification, MFCC, BiLSTM, Audio Signal Processing, Biodiversity Conservation

1. Pendahuluan

Suara kicauan burung yang merdu dan beragam menjadikan setiap spesies memiliki karakteristik akustik yang unik, namun variasi besar dalam kicauan burung baik antar spesies maupun intra spesies membuat klasifikasi menjadi tantangan kompleks [1]. Indonesia dengan keanekaragaman 1.835 spesies burung yang tersebar di berbagai habitat mulai dari hutan dataran rendah, pegunungan, lahan basah hingga pesisir [2], memerlukan pemantauan suara yang akurat untuk mendukung upaya pelestarian keanekaragaman hayati. Perkembangan teknologi artificial intelligence dalam bidang konservasi dan ekologi telah memungkinkan otomatisasi proses identifikasi spesies burung melalui analisis akustik menggunakan machine learning dan *deep learning* [3], yang menjadi krusial mengingat habitat burung yang semakin terancam dan kebutuhan monitoring biodiversitas yang efisien.

Berbagai penelitian terdahulu menunjukkan hasil menjanjikan dengan pendekatan beragam. Dewi dan Juniati (2023) mencapai akurasi 87.5% menggunakan Dimensi Fraktal Higuchi dan *K-Nearest Neighbor* untuk 8 spesies burung nokturnal, namun terbatas dalam menangkap kompleksitas temporal [4]. Putra et al. (2024) menerapkan kombinasi MFCC dan *Naive Bayes* dengan akurasi 88% untuk burung cucak, dimana MFCC efektif merepresentasikan spektrum suara tetapi kurang optimal untuk dependensi temporal kompleks [5]. Xie dan Zhu (2023) menggunakan fusion deep features dari model pre-trained mencapai akurasi 94.89% pada 43 spesies burung, namun tanpa eksplorasi temporal mendalam [6]. Wang et al. (2025) mengusulkan DFEFM dengan akurasi 91.4% melalui kombinasi MFCC dan *frequency correlation*, tetapi belum memanfaatkan model *bidirectional* [7]. Atharsyah dan Romli (2024) menunjukkan potensi BiLSTM dalam prediksi data time series, namun belum mengoptimalkan ekstraksi fitur MFCC untuk karakteristik suara burung Indonesia [8].

Berdasarkan gap penelitian tersebut, penelitian ini mengusulkan kombinasi ekstraksi fitur MFCC dengan model BiLSTM untuk klasifikasi jenis burung berdasarkan suara kicau. *Novelty* terletak pada optimalisasi parameter MFCC yang disesuaikan dengan karakteristik frekuensi suara burung Indonesia dikombinasikan dengan arsitektur BiLSTM. MFCC dipilih karena efektif mengekstrak fitur spektral dengan meniru sistem pendengaran manusia melalui transformasi mel-scale [9], sementara BiLSTM unggul mempelajari pola temporal jangka panjang dari kedua arah yang krusial dalam analisis vokal burung dengan struktur temporal kompleks [10]. Tujuan penelitian ini adalah mengembangkan sistem klasifikasi otomatis untuk identifikasi jenis burung dengan akurasi tinggi guna mendukung konservasi keanekaragaman hayati melalui pemantauan akustik yang efisien dan berkelanjutan.

2. Metodologi

Metodologi penelitian digambarkan dalam gambar 1, dimana memberikan pedoman yang sistematis dan menyeluruh tentang alur penelitian. Mulai terdiri dari tahap pengumpulan data, preprocessing, augmentasi, ekstraksi fitur, modeling hingga evaluasi. Tujuan dari tahapan penelitian ini adalah untuk memastikan bahwa penelitian yang dilakukan dengan tepat, objektif, sehingga hasil dapat dipertanggungjawabkan dan valid.

Penelitian dilakukan menggunakan model deep learning yaitu BiLSTM untuk tujuan memprediksi jenis burung berdasarkan suara kicau. Berikut rangkaian dari penelitian.


2.1 Pengumpulan Dataset

Dataset dalam penelitian ini diperoleh dari *platform xeno-canto.org*, sebuah repositori global yang menyediakan rekaman suara burung dari berbagai spesies. Sepuluh spesies burung yang umum dijumpai di Indonesia dipilih sebagai objek klasifikasi yang dapat dilihat di tabel 1.

2.2 Data Preprocessing

Tahap *preprocessing* mempersiapkan data audio mentah menjadi format yang sesuai untuk pemrosesan lebih lanjut dengan melakukan beberapa tahapan berurutan. Dataset audio burung yang telah dikumpulkan dari xeno-canto.org dalam format WAV dimuat dan dikonversi menjadi *mono channel*, kemudian dilakukan normalisasi volume untuk memastikan konsistensi amplitudo antar file audio dan disegmentasi menjadi potongan berukuran 4 detik tanpa *overlap*. Setiap segmen diekspor sebagai file terpisah dan disimpan sesuai klasifikasi spesies burungnya, menghasilkan 75 segmen audio per spesies dengan total 750 segmen untuk 10 spesies burung yang diteliti. Proses preprocessing dilanjutkan dengan normalisasi amplitudo untuk memastikan nilai amplitudo audio berada dalam rentang [-1, 1] untuk konsistensi input model. Penerapan

Wiener filter untuk mengurangi noise pada sinyal audio serta meningkatkan kualitas *signal-to-noise ratio*, kemudian teknik *padding* atau *truncation* untuk memastikan semua segmen memiliki panjang yang konsisten.



Gambar 1. Tahapan Penelitian

Tabel 1. Dataset Burung

Nama Burung	Nama Latin	Jumlah Segmen
Kenari	<i>Serinus canaria</i>	75
Pleci	<i>Zosterops</i>	75
Lovebird	<i>Agapornis</i>	75
Burung Gereja	<i>Passer montanus</i>	75
Sikatan Hitam	<i>Turdus merula</i>	75
Perkutut	<i>Geopelia striata</i>	75
Kutilang	<i>Pycnonotus aurigaster</i>	75
Srigunting	<i>Dicrurus hottentottus</i>	75
Kipasan Belang	<i>Rhipidura javanica</i>	75
Trucukan	<i>Pycnonotus goiavier</i>	75

2.3 Augmentasi

Teknik augmentasi data diterapkan untuk meningkatkan diversitas *dataset* dan mengurangi *overfitting*. Teknik augmentasi data diterapkan pada setiap segmen audio 4 detik yang telah dihasilkan dari tahap preprocessing untuk meningkatkan variasi data pelatihan. Dua teknik utama yang diimplementasikan adalah sebagai berikut:

a. Pitch Shift


Pitch shift mengubah nada suara tanpa mengubah durasi, dengan menaikkan atau menurunkan frekuensi suara burung sebanyak ± 2 semitone [10]. Teknik ini mensimulasikan variasi alami suara burung akibat faktor lingkungan atau individu, meningkatkan robustitas model terhadap variasi pitch.

b. Time Stretch

Teknik ini memperluas atau mempersingkat durasi segmen audio, membantu model belajar dari variasi temporal suara burung yang mungkin terjadi di alam liar [10]. *Time stretch* mengubah kecepatan suara tanpa mengubah *pitch*, dengan faktor *stretch* antara 0,9 hingga 1,1 .

2.4 Ekstraksi Fitur

Ekstraksi fitur suara menggunakan *Mel-Frequency Cepstral Coefficient* (MFCC) merupakan bagian penting dalam pengenalan suara burung, memungkinkan sistem untuk mengidentifikasi karakteristik unik dari kicauan. Algoritma *Mel-Frequency Cepstral Coefficients* (MFCC) sering digunakan untuk mengekstrak fitur suara. Algoritma ini mengubah representasi suara dari *domain* waktu ke *domain* frekuensi, meniru kemampuan telinga manusia dalam membedakan suara berdasarkan frekuensi untuk mengekstrak fitur-fitur penting dari suara burung [11]. Dalam konteks ini, audio yang telah diproses dengan normalisasi volume dan segmentasi menjadi potongan 4 detik untuk analisis lebih lanjut. Proses ekstraksi fitur MFCC secara umum dapat dilihat pada Gambar 2.



Gambar 2. Proses *Mel-Frequency Cepstral Coefficient*

a. *Pra-emphasis*

Pre-emphasis dilakukan setelah data sampel suara diproses untuk meningkatkan amplitudo frekuensi tinggi, sehingga mengurangi *noise* dan memperbaiki bentuk spektral sinyal suara. Proses ini membantu menghasilkan spektral dengan nilai tinggi pada frekuensi rendah yang cenderung menurun pada frekuensi di atas 2000 Hz [11].

b. *Frame Blocking*

Sinyal suara dibagi menjadi beberapa *frame* pendek (umumnya 20-40 ms) dengan *overlap* sekitar 50%. Teknik ini mengubah sinyal yang bervariasi dengan waktu menjadi urutan sinyal yang hampir konstan, memungkinkan analisis dalam *domain* frekuensi menggunakan transformasi *Fourier* [12]. Dalam berkas, setiap segmen 4 detik dianalisis untuk memastikan analisis temporal yang konsisten.

c. *Windowing*

Setiap *frame* diproses dengan fungsi *windowing*, seperti *Hamming window*, untuk mengurangi efek transien pada awal dan akhir segmen sinyal suara. Proses ini membuat sinyal lebih halus dan memudahkan analisis spektral [12].

d. *Fast Fourier Transform* (FFT)

FFT mengonversi sinyal dari *domain* waktu ke *domain* frekuensi untuk menghasilkan spektrum daya [11]. Proses ini memungkinkan pengurangan spektral dan analisis komponen frekuensi dari setiap *frame* suara burung.

e. *Mel-Frequency Wrapping*

Spektrum daya dari setiap *frame* difilter menggunakan bank filter *Mel-scale* dengan 20-40 filter segitiga. Filter ini meniru persepsi pendengaran manusia yang linier di bawah 1 kHz dan logaritmik di atasnya, menghasilkan energi filter yang merepresentasikan karakteristik suara [11].

f. *Log*

Logaritma diterapkan pada energi *Mel-filterbank* untuk mengkompresi rentang dinamis, menghasilkan *log Mel-spectrum* yang sesuai dengan persepsi manusia terhadap intensitas suara [12].


g. *Discrete Cosine Transform* (DCT)

DCT mengubah *log Mel-spectrum* menjadi *domain cepstral* untuk menghasilkan koefisien MFCC [12]. Dalam penelitian ini, 40 koefisien MFCC diekstrak untuk memberikan representasi fitur yang lebih komprehensif.

Dalam implementasi penelitian ini, seluruh tahapan di atas dilakukan secara otomatis menggunakan *library* pemrosesan audio untuk ekstraksi 40 koefisien MFCC. Hasil ekstraksi kemudian dirata-ratakan secara temporal untuk menghasilkan vektor fitur dengan dimensi tetap 40 koefisien per segmen audio 4 detik.

2.5 Pemodelan

Bidirectional Long Short-Term Memory (BiLSTM) adalah varian dari LSTM yang memproses urutan data secara maju (*forward*) dan mundur (*backward*) untuk menangkap konteks temporal dari kedua arah. Model ini sangat efektif untuk klasifikasi suara burung karena mampu menangani ketergantungan jangka panjang dalam urutan fitur MFCC [13], seperti yang digunakan dalam berkas untuk memproses segmen audio 4 detik.



Gambar 3. Arsitektur Model BiLSTM

Gambar 3 menunjukkan arsitektur BiLSTM yang digunakan. Model terdiri dari dua lapisan LSTM bidirectional. Setiap lapisan diikuti dengan *dropout* dan *batch normalization*. Lapisan tersembunyi menggunakan aktivasi ReLU. Lapisan output menggunakan aktivasi *softmax* untuk klasifikasi multi-kelas.

BiLSTM dipilih karena suara burung memiliki pola frekuensi kompleks. Informasi penting dapat muncul di awal, tengah, atau akhir segmen audio. Pendekatan *bidirectional* mempertimbangkan konteks dari kedua arah. Hal ini membantu menangkap fitur-fitur distintif yang mungkin terlewat.

Tabel 2. Detail Model BiLSTM

Layer Type	Output Shape	Parameters
Bidirectional LSTM	(None, 40, 256)	133,12
Dropout (0.3)	(None, 40, 256)	0
Batch Normalization	(None, 40, 256)	1,024
Bidirectional LSTM	(None, 128)	164,352
Dropout (0.3)	(None, 128)	0
Batch Normalization	(None, 128)	512
Dense (ReLU)	(None, 128)	16,512
Dropout (0.3)	(None, 128)	0
Batch Normalization	(None, 128)	512
Dense (ReLU)	(None, 64)	8,256
Dropout (0.3)	(None, 64)	0
Batch Normalization	(None, 64)	256
Dense (Softmax)	(None, 10)	650
	Trainable parameters	324042
	Non-trainable parameters	1152
	Total Parameters	325194

Berdasarkan Tabel 2, penelitian ini menggunakan dua lapisan BiLSTM dengan 256 dan 128 unit karena konfigurasi ini menghasilkan total parameter 325.194 yang optimal untuk *dataset* suara burung. Dropout rate 0.3 dipilih karena memberikan keseimbangan antara regularisasi dan kemampuan pembelajaran model. *Batch normalization* diterapkan setelah setiap lapisan karena dapat menstabilkan *training* dengan parameter non-trainable hanya 1.152.

Lapisan dense dengan aktivasi ReLU dipilih karena memberikan *non-linearity* yang diperlukan untuk klasifikasi kompleks dengan parameter yang efisien (16.512 dan 8.256). *Output layer* menggunakan *softmax* dengan 650 parameter karena sesuai untuk klasifikasi 10 kelas suara burung.

Tabel 3. Hyperparameter dan tuning parameter BiLSTM

Parameter	Value
Batch size	16
Epochs	200
Loss Function	Sparse Categorical Crossentropy
Optimizer	Adam with learning rate 0.001
Early Stopping	Monitor='val_loss', patience=50
Model Checkpoint	Monitor='val_loss', save_best_only=True
Input shape	(40,1) – From X_train.shape
BiLSTM layers	2 Bidirectional LSTM layers (128 , 64 units) with 30% dropout and batch normalization
Dense Layers	2 Dense layers (128, 64 units) + output layer with ReLU activation and Softmax output, 30% dropout and batch normalization

Berdasarkan Tabel 3, *batch size* 16 digunakan karena memberikan keseimbangan antara efisiensi komputasi dan stabilitas *training*. Learning rate 0.001 dengan Adam optimizer dipilih karena memberikan konvergensi yang stabil untuk data sequential. *Early stopping* dengan *patience* 50 diterapkan karena mencegah *overfitting* sambil memberikan waktu cukup untuk konvergensi optimal.

Sparse categorical crossentropy digunakan karena sesuai dengan format label integer untuk 10 kelas. Dropout 30% dan *batch normalization* diterapkan karena efektif mencegah *overfitting* pada data audio yang memiliki variasi tinggi.

2.6 Confusion Matrix

Untuk mengevaluasi keefektifan metode klasifikasi jenis burung berdasarkan suara kicau menggunakan MFCC dan BiLSTM, hasil klasifikasi dianalisis untuk menentukan tingkat keberhasilannya. *Confusion Matrix* merupakan salah satu alat evaluasi yang paling efektif untuk menganalisis performa model klasifikasi *multi-kelas*, khususnya dalam konteks pengenalan suara burung yang memiliki karakteristik akustik yang beragam. Analisis ini melibatkan perhitungan metrik performa seperti *Accuracy*, *Precision*, *Recall*, dan *F1-Score* yang diperoleh dari komponen-komponen dalam *confusion matrix* [14].

Confusion Matrix menyajikan korelasi antara *output* prediktif model dengan kategori yang sesungguhnya dalam format tabular, dengan sumbu vertikal menggambarkan kategori asli spesies dan sumbu horizontal mewakili kategori hasil prediksi sistem BiLSTM. Tiap sel dalam matriks mengindikasikan kuantitas sampel dari spesies spesifik yang dikategorikan ke dalam kelas prediksi tertentu, memfasilitasi deteksi pola klasifikasi karakteristik di antara berbagai spesies burung [15].

1. Accuracy

Akurasi mencerminkan kemampuan keseluruhan model dalam memberikan prediksi yang tepat untuk spesies burung dari keseluruhan sampel audio yang dievaluasi.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \cdot 100 \quad (1)$$

2. *Precision* Presisi merepresentasikan tingkat ketepatan antara prediksi spesies burung yang ditargetkan dengan output klasifikasi yang dihasilkan oleh arsitektur BiLSTM.

$$Precision = \frac{TP}{TP+FP} \quad (2)$$

3. Recall

Recall menggambarkan kemampuan sistem dalam mengidentifikasi secara akurat seluruh sampel audio dari spesies burung yang spesifik.

$$Recall = \frac{TP}{TP+FN} \quad (3)$$

4. F1-Score

F1-Score diperoleh melalui kombinasi nilai Presisi dan Sensitivitas yang menyediakan keseimbangan optimal antara kedua parameter tersebut dalam penilaian klasifikasi spesies burung.

$$F1\ Score = 2 \cdot \frac{Recall \cdot Precision}{Recall+Precision} \quad (4)$$

Dimana :

- TP : *true positive* (jumlah data kelas positif yang diprediksi benar sebagai positif)
 FP : *false positive* (jumlah data kelas negatif yang salah diprediksi sebagai positif)
 FN : *false negative* (jumlah data kelas positif yang salah diprediksi sebagai negatif)
 TN : *true negative* (jumlah data kelas negatif yang diprediksi benar sebagai negatif)

3. Hasil Dan Pembahasan

3.1 Dataset

Dataset penelitian ini menggunakan 10 spesies burung Indonesia yang umum dijumpai dapat dilihat pada tabel 1, dengan data audio yang diperoleh dari *platform xeno-canto.org*. Setiap spesies burung memiliki karakteristik vokal yang unik, sehingga pemilihan spesies ini bertujuan untuk menguji kemampuan model dalam membedakan variasi suara yang beragam.

3.2 Preprocessing

Tahapan ini diawali dengan data awal berupa file MP3 yang bervariasi dikonversi ke format WAV dengan frekuensi sampling 16kHz untuk konsistensi pemrosesan. Segmentasi audio dilakukan dengan memotong setiap file menjadi segmen berdurasi 4 detik menggunakan *library pydub*. Durasi ini dipilih karena cukup menangkap karakteristik vokal burung tanpa menyulitkan pembelajaran model. Hasil segmentasi menghasilkan 75 segmen per spesies, total 750 segmen dengan distribusi seimbang untuk mencegah bias pembelajaran.

Proses *preprocessing* selanjutnya meliputi normalisasi amplitudo ke rentang $[-1, 1]$ untuk konsistensi volume, penerapan Wiener filter untuk mengurangi noise latar belakang sambil mempertahankan karakteristik sinyal asli, dan *padding/truncation* untuk memastikan panjang data seragam. Tahapan ini memastikan data input berkualitas dan format konsisten.

3.3 Augmentasi Data

Teknik augmentasi diterapkan untuk meningkatkan diversitas *dataset* dan mencegah *overfitting*. *Pitch shift* mengubah nada suara ± 2 *semitone* tanpa mengubah durasi, mensimulasikan variasi natural akibat faktor lingkungan. *Time stretch* mengubah kecepatan audio dengan faktor 0.9-1.1 tanpa mengubah *pitch*, membantu model belajar variasi temporal.

Augmentasi berhasil meningkatkan *dataset* dari 750 menjadi 3.750 sampel (setiap audio menghasilkan 4 varian tambahan), memberikan variasi realistis sesuai kondisi natural dan signifikan meningkatkan kemampuan generalisasi model.

3.4 Ekstraksi Fitur MFCC

Berdasarkan metodologi yang telah ditetapkan, proses ekstraksi fitur MFCC diimplementasikan pada keseluruhan 3.750 segmen audio menggunakan parameter $n_{mfcc} = 40$. Implementasi ini menghasilkan representasi spektral yang menangkap karakteristik frekuensi unik setiap spesies melalui transformasi sinyal audio menjadi vektor 40 dimensi dengan teknik averaging temporal untuk memastikan stabilitas fitur.

Tabel 4. Sampel output MFCC

Sampel	Dataset	MFCC
1	datasets/4s_segments\Keni\segment_0_0.wav	[27.61327698, 58.15089575, 36.14110608, 21.81186055, -9.10658971, 7.59974329, 0.89529332, -0.3987648, 2.43515224, 1.01835707, 2.92207722, -1.11498169, 0.26630695, -0.70938684, 1.32169582, 1.87539736, 2.44313139, -1.21931837, -0.92131625, 5.78323065, 6.71400468, 0.64323427, -2.94037124, 1.01934932, -0.83336113, 2.45124906, 1.73969932, 1.50109864, 1.53151764, 0.73440256, 0.07033285, -0.283223, -0.32649602, -0.84923811, 1.99261201, 0.22004276, 0.73636554, -0.65987887, -0.32991584, 3.27947272]
.....		

Gambar 4 menunjukkan sampel hasil ekstraksi fitur MFCC dari segmen audio suara burung. Proses ekstraksi menghasilkan *dataset* fitur terstruktur dalam format CSV yang memuat informasi path file, label spesies, dan 40 koefisien MFCC untuk setiap segmen. Hasil transformasi ini menunjukkan bahwa setiap vektor MFCC mampu merepresentasikan karakteristik spektral yang distinktif dari pola akustik masing-masing spesies burung, sehingga dapat digunakan sebagai input yang optimal untuk arsitektur BiLSTM.


3.5 BiLSTM

Berdasarkan arsitektur yang telah ditetapkan pada Tabel 1.2, model menggunakan dua lapisan BiLSTM dengan 256 unit (lapisan pertama) dan 128 unit (lapisan kedua), diikuti dengan dua lapisan dense dengan 128 dan 64 unit yang menggunakan aktivasi ReLU. Total parameter yang digunakan adalah 325,194 dengan 324,042 parameter trainable dan 1,152 parameter non-trainable. Konfigurasi hyperparameter sesuai Tabel 1.3 untuk mencegah *overfitting*. Epochs ditetapkan maksimal 200 dengan *early stopping patience* 50, namun *training* berhenti pada epoch 124 karena *validation loss* tidak menunjukkan perbaikan selama 50 *epoch* berturut-turut, mencapai nilai minimum 0.0788. Hasil pelatihan BiLSTM bisa dilihat di tabel 3.2 sebagai berikut

Tabel 5. Hasil Pelatihan BiLSTM

Epoch	Akurasi Pelatihan	Loss Pelatihan	Akurasi Validasi	Loss Validasi
1	28.17%	2.1381	55.87%	1.3798
10	81.63%	0.5839	90.53%	0.3109
20	91.10%	0.2757	95.33%	0.1292
50	96.70%	0.1125	97.07%	0.1039
100	98.57%	0.0555	97.47%	0.0986
120	98.60%	0.0493	98.13%	0.0871
123	98.70%	0.0438	96.93%	0.1974
124	98.53%	0.0504	97.60%	0.0788

Berdasarkan Gambar 4, grafik pelatihan menunjukkan *training* dan *validation accuracy* meningkat paralel hingga 98% tanpa gap signifikan, mengindikasikan tidak ada *overfitting*. Loss menurun konsisten dengan *validation loss* mencapai minimum 0.08 pada epoch 124. Model dikatakan bagus karena konvergensi optimal dengan *early stopping* dan *validation accuracy* konsisten di atas 95%.



Gambar 4. Grafik Pelatihan BiLSTM

Model BiLSTM memproses fitur MFCC yang membentuk data sekuensial dengan pendekatan bi-directional untuk menangkap pola temporal dari kedua arah. Hasil evaluasi menunjukkan akurasi klasifikasi 98%.


Tabel 6. Hasil Klasifikasi BiLSTM

Kelas	Precision	Recall	F1-Score	Support
Burung Gereja	97%	91%	94%	69
Kenari	96%	98%	97%	93
Kipasan Belang	96%	95%	96%	81
Kutilang	99%	97%	98%	74
Lovebird	98%	100%	98%	80
Perkutut	99%	97%	99%	73
Pleci	96%	100%	98%	76
Sikatan Hitam	99%	99%	99%	72
Srigunting	99%	99%	99%	73
Trucukan	100%	100%	100%	59
Average	98%	98%	98%	750

Terlihat pada tabel 6 hasil yang diperoleh, model mencapai nilai *precision* tertinggi pada kelas Trucukan (100%) dan terendah pada kelas Kenari, Kipasan Belang, dan Pleci (96%). Untuk recall, nilai tertinggi dicapai pada kelas Lovebird, Pleci, Trucukan (100%) dan terendah pada kelas Burung Gereja (91%). Sedangkan F1-Score tertinggi diperoleh pada kelas Trucukan (100%) dan terendah pada kelas Burung Gereja (94%). Nilai akurasi keseluruhan sebesar 98% menunjukkan bahwa model BiLSTM sangat efektif dalam mengklasifikasikan suara burung berdasarkan fitur MFCC.

3.6 Confusion Matrix

Confusion Matrix berperan sebagai instrumen kunci dalam mengukur performa sistem klasifikasi. Matriks ini menyajikan visualisasi komprehensif mengenai kemampuan model dalam mengkategorikan data ke dalam kelas yang tepat. Empat komponen utama dalam matriks ini terdiri dari *True Positive* (TP) yang merepresentasikan keberhasilan model dalam memprediksi kelas positif dengan benar, *True Negative* (TN) yang menunjukkan akurasi model dalam mengidentifikasi kelas negatif, *False Positive* (FP) yang menandakan kesalahan klasifikasi dimana data negatif terprediksi sebagai positif, dan *False Negative* (FN) yang mencerminkan kegagalan model dalam mendeteksi instance positif.



Gambar 5. Hasil Confusion Matrix

Berdasarkan analisis Gambar 5, teramati bahwa model menunjukkan performa yang mengesankan dengan dominasi nilai pada diagonal utama. Sebanyak 63 sampel Burung Gereja berhasil diidentifikasi dengan tepat, disusul oleh 91 sampel Kenari, 77 sampel Kipasan Belang, dan seterusnya hingga 59 sampel Trucukan. Capaian ini mengindikasikan bahwa model memiliki kemampuan yang solid dalam mengenali pola suara yang khas dari masing-masing spesies.

Meskipun demikian, terdapat beberapa kesalahan klasifikasi yang perlu dicermati. Tiga sampel Burung Gereja terklasifikasi sebagai Sikatan Hitam, dan dua sampel lainnya terdeteksi sebagai Lovebird. Sementara itu, dua sampel Kipasan Belang mengalami misklasifikasi sebagai Kenari, dan satu sampel lainnya teridentifikasi sebagai Perhutut. Fenomena ini mengisyaratkan adanya kemiripan karakteristik akustik antar spesies-spesies tersebut, yang menjadi tantangan tersendiri bagi model dalam melakukan diferensiasi.

Analisis mendalam terhadap pola kesalahan klasifikasi ini memberikan wawasan berharga untuk pengembangan model di masa depan. Pemahaman mengenai titik kelemahan model dalam membedakan spesies-spesies tertentu dapat menjadi dasar untuk melakukan optimasi fitur, penyempurnaan arsitektur model, atau penambahan data *training* pada kelas-kelas yang memiliki kemiripan karakteristik.

Tabel 7. Perbandingan Performa

Peneliti	Metode	Objek	Akurasi
Penelitian Dewi & Juniati, 2023 [4]	Dimensi Fraktal Higuchi & KNN	Suara Burung	87,5%
Penelitian Putra et al., 2024 [5]	MFCC & Naive Bayes	Suara Burung	90%
Penelitian saat ini	MFCC & BiLSTM	Suara Burung	98%

Terlihat tabel 7, Hasil menunjukkan peningkatan signifikan dibanding metode sebelumnya. Keunggulan BiLSTM terletak pada kemampuannya menangkap dependensi temporal *bi-directional* dalam sinyal audio, memberikan pemahaman konteks yang lebih komprehensif dibanding metode tradisional seperti KNN atau *Naive Bayes*.

4. Kesimpulan

Penelitian ini menunjukkan bahwa kombinasi ekstraksi fitur MFCC dengan model BiLSTM adalah teknik yang efektif untuk klasifikasi suara burung. Hasil pengujian pada 10 spesies burung Indonesia dengan pembagian data 80:20 menunjukkan bahwa model BiLSTM mampu mencapai akurasi prediksi yang sangat tinggi sebesar 98%. Keberhasilan model ini dalam mencapai tingkat akurasi tersebut menunjukkan kemampuannya dalam mengidentifikasi pola temporal *bi-directional* dan karakteristik spektral yang unik dari setiap jenis suara burung. Teknik augmentasi data terbukti meningkatkan performa model dengan memperbanyak variasi dataset dari 750 menjadi 3.750 sampel. Hasil *confusion matrix* menunjukkan bahwa 98% dari data suara burung diprediksi benar ke masing-masing spesiesnya, dengan kesalahan klasifikasi minimal. Dengan demikian, dapat disimpulkan bahwa penerapan MFCC dan BiLSTM dapat digunakan secara efektif untuk mengklasifikasikan burung Indonesia berdasarkan suara, yang dapat diaplikasikan untuk mendukung upaya pemantauan biodiversitas dan konservasi keanekaragaman hayati burung.

Daftar Pustaka

- [1] D. Iakubovskiy, "Chirp to Classification: Identifying 50 Bird Species by Sound with Transformer-Based Machine Learning Model," *Data And Beyond (Medium)*, 2023. [Online]. Available: <https://medium.com/data-and-beyond/chirp-to-classification-identifying-50-bird-species-by-sound-with-transformer-based-machine-dfd46979847a>.
- [2] B. Indonesia, "Status Burung di Indonesia 2025," *Burung.org*, 2025. [Online]. Available: <https://burung.org/informasi-burung/status-burung-di-indonesia-2025/>.
- [3] K. S. Bobba, K. K. V. K. Sai, D. Bugga, and V. M. S. Bolla, "AI-Enhanced Acoustic Analysis for Comprehensive Biodiversity Monitoring and Assessment," 2024.
- [4] A. S. Dewi and D. Juniati, "Klasifikasi Burung Nokturnal Berdasarkan Suara Menggunakan Dimensi Fraktal Higuchi Dan K-Nearest Neighbor," *J. Ris. dan Apl. Mat.*, vol. 7, no. 2, pp. 177–194, 2023.
- [5] Muhammad Romadloni Putra, F. Nurdiansyah, and A. Yuniar Rahman, "Klasifikasi Jenis Burung Cucak Berdasarkan Suara Menggunakan MFCC Dan Naive Bayes," *J. Fasilkom*, vol. 14, no. 2, pp. 463–470, 2024.

- [6] J. Xie and M. Zhu, "Acoustic Classification of Bird Species Using an Early Fusion of Deep Features," *Birds*, vol. 4, no. 1, pp. 138–147, 2023.
- [7] Y. Wang, L. Zhang, J. Xie, J. Zhang, and R. Zhu, "DFEFM: Fusing frequency correlation and mel features for robust edge bird audio detection," *Avian Res.*, vol. 16, no. 2, p. 100232, 2025.
- [8] Muhammad Atharsyah and M. A. Romli, "Implementasi Model Lstm, Gru, Bilstm, Dan Bigru Dalam Prediksi Harga Nikel," *J. Inform. dan Rekayasa Elektron.*, vol. 7, no. 2, pp. 413–420, 2024.
- [9] S. Y. Yusdiantoro and T. B. Sasongko, "Implementasi Algoritma MFCC dan CNN dalam Klasifikasi Makna Tangisan Bayi," *Indones. J. Comput. Sci.*, vol. 12, no. 4, pp. 1957–1968, 2023.
- [10] F. F. Dias, M. A. Ponti, and R. Minghim, "Enhancing sound-based classification of birds and anurans with spectrogram representations and acoustic indices in neural network architectures," *Ecol. Inform.*, vol. 90, no. April, p. 103232, 2025.
- [11] A. Alamsyah, F. Ardiansyah, and A. Kholiq, "Music Genre Classification Using Mel Frequency Cepstral Coefficients and Artificial Neural Networks: A Novel Approach," *Sci. J. Informatics*, vol. 11, no. 4, pp. 937–948, 2024.
- [12] H. Nugroho, A. Rachman, and I. Albana, "Penerapan Metode Levenshtein Distance untuk Mengukur Similaritas pada Pola Suara Burung yang Menggunakan Discrete Cosine Transform," *J. Eksplora Inform.*, vol. 12, no. 2, pp. 95–103, 2023.
- [13] A. S. Kumar, T. Schlosser, S. Kahl, and D. Kowerko, "Improving learning-based birdsong classification by utilizing combined audio augmentation strategies," *Ecol. Inform.*, vol. 82, no. June, 2024.
- [14] O. I. Christopher, "Emotion Detection Using a Bidirectional Long-Short Term Memory (BiLSTM) Neural Network," *Int. J. Res. Publ. Rev.*, vol. 4, no. 11, pp. 1718–1732, 2023.
- [15] C. Zhang, H. Zhan, Z. Hao, and X. Gao, "Classification of Complicated Urban Forest Acoustic Scenes with Deep Learning Models," *Forests*, vol. 14, no. 2, 2023.